
Recomendación de noticias clickbait-aware sobre dataset MIND

Clemente Campos¹ Alvaro Restuccia¹ Max Reyes¹

Abstract

En la recomendación de noticias, optimizar únicamente los clics puede favorecer titulares llamativos o clickbait, lo que afecta negativamente la experiencia del usuario a largo plazo. Por lo tanto, el problema no consiste solo en recomendar noticias relevantes, sino también en reducir señales no deseadas como el clickbait, la baja diversidad temática y la baja novedad. En este proyecto, partimos de un ranking interpretable basado en TF-IDF y estudiamos si es posible reordenarlo utilizando características de clickbait, novedad y diversidad, con el objetivo de generar recomendaciones más informativas sin perder un rendimiento significativo en métricas de precisión como AUC, MRR y nDCG@10.

1. Introducción

El problema principal que motiva esta investigación es que los sistemas de recomendación de noticias tradicionales, al optimizar basándose únicamente en la probabilidad de clic (CTR), tienden a favorecer artículos con titulares engañosos o exagerados, conocidos comúnmente como *clickbait*. Esto puede degradar significativamente la confianza del usuario y su satisfacción con la plataforma.

Por lo tanto, nuestro objetivo es incorporar dimensiones de calidad informativa en la recomendación. Específicamente, buscamos penalizar el contenido clickbait y promover la novedad y diversidad en las noticias recomendadas, partiendo de un modelo base interpretable (TF-IDF) y aplicando un *re-ranking* multimodal.

2. Revisión del estado del arte

La literatura reciente en sistemas de recomendación de noticias ha avanzado enormemente gracias a la introducción

de datasets a gran escala. El trabajo de Wu et al. (2020) introdujo el dataset MIND (MICrosoft News Dataset), que ha servido como estándar para evaluar modelos complejos como DSSM, Wide&Deep y DeepFM. Sin embargo, la mayoría de estos métodos optimizan fuertemente la probabilidad de clic sin considerar la calidad del contenido, lo que en la práctica podría favorecer la recomendación de *clickbait*.

La detección de *clickbait* ha evolucionado desde la extracción manual de características hasta arquitecturas neuronales complejas. Históricamente, trabajos pioneros como el de Biyani et al. (2016) se basaron en ingeniería de características (*feature engineering*) para detectar clickbait, demostrando que factores léxicos y sintácticos como el uso de superlativos, exceso de signos de puntuación, mayúsculas injustificadas, y la discrepancia semántica entre el título y el cuerpo de la noticia son fuertes predictores de informalidad y engaño. En años más recientes, las investigaciones han abordado la detección mediante modelos de lenguaje pre-entrenados (como BERT) para analizar de manera más profunda las "brechas de curiosidad" (*curiosity gaps*) y la consistencia multimodal en las noticias (Scott, 2021; Natanya & Liebeskind, 2025).

En nuestro trabajo, optamos por basarnos en las señales léxicas y estructurales clásicas propuestas por Biyani et al., ya que resultan sumamente eficientes y transparentes para construir un *ClickbaitScore*. A diferencia de enfoques de la literatura que se enfocan puramente en clasificar o filtrar noticias, nuestra contribución radica en integrar estas características de calidad directamente como objetivos de *re-ranking* en un sistema de recomendación, penalizando el clickbait mientras se preserva el desempeño de las sugerencias (AUC/NDCG).

3. Dataset

La Tabla 1 resume las estadísticas principales de los conjuntos de entrenamiento y validación del dataset MIND.

Se utilizó un subconjunto del dataset MIND (MIND Small) balanceado con 50.000 usuarios únicos tanto en el conjunto de entrenamiento como en el de validación. El dataset recopila el comportamiento de clics sobre un catálogo dinámico de noticias que abarca 17 categorías generales y más de 250 subcategorías.

¹Departamento de Ciencia de la Computación, Pontificia Universidad Católica de Chile, Chile. Correspondence to: Grupo de Trabajo <grupo@uc.cl>.

Table 1. Resumen de datos de entrenamiento y validación (subconjunto MIND Small).

Métrica	Train	Validation
Impresiones	156.965	73.152
Usuarios únicos	50.000	50.000
Noticias	51.282	42.416
Categorías	17	17
Subcategorías	264	257
Candidatos totales	5.843.444	2.470.998
Clicks totales	236.344	111.383
CTR	0.0404	0.0406
Promedio candidatos/impresión	37.23	37.47
Mediana historial usuario	24	23
Entity embeddings	26.904	22.893

El comportamiento de los usuarios es altamente denso, registrando una mediana de historial de 24 interacciones en Train y 23 en Validation. No obstante en el Gráfico 1 se puede observar que el catálogo presenta un fuerte desbalance en sus temáticas: las categorías de “News” y “Sports” dominan drásticamente el volumen de noticias disponibles, sumando más de 30.000 artículos en el conjunto de entrenamiento, mientras que el resto de las áreas exhibe una presencia significativamente menor.




Figure 1. Distribución de categorías de noticias en el dataset, destacando el fuerte desbalance hacia *news* y *sports*.

El dataset registra un volumen masivo de candidatos recomendados, superando los 5.8 millones en entrenamiento y los 2.4 millones en validación, manteniendo una media consistente de aproximadamente 37 candidatos por impresión. A pesar del enorme espacio de búsqueda, el Click-Through Rate (CTR) se mantiene sumamente estable en torno al 4.04 % - 4.06 % en ambos conjuntos.

Como se puede observar, el volumen masivo de impresiones, noticias y candidatos totales contrasta con una mediana de historial por usuario relativamente concentrada, lo que subraya el desafío de seleccionar artículos relevantes y diversos entre decenas de candidatos por cada impresión.

4. Metodología utilizada

Nuestra metodología se dividió en los siguientes pasos:

1. Representación base: Primero se representó cada noticia mediante un vector TF-IDF (Term Frequency - Inverse Document Frequency) calculado sobre la concatenación del título y el resumen (abstract). Para la recomendación, se construyó un perfil de usuario promediando las representaciones de las noticias en su historial de clics. El ranking base se generó calculando la similitud coseno entre el perfil del usuario y las noticias candidatas.

2. Variantes de Re-ranking: Se comparó el modelo TF-IDF base contra las siguientes variantes diseñadas para optimizar objetivos multimodales: *Random*, *Most Popular*, *TF-IDF + Low Clickbait*, *TF-IDF + Novelty* y un *Re-ranking Completo/Optimizado*.

3. Entrenamiento y validación: Se utilizó la partición estándar del dataset MIND Small, empleando los conjuntos de *train* para el cálculo de popularidad y entrenamiento de representaciones, y el conjunto de *dev* (limitado a las primeras 5.000 impresiones) como set de validación/test para medir el desempeño del ranking.

4. Métricas: Es importante destacar cómo se define la relevancia en el contexto del dataset MIND: para una impresión (sesión) dada, si el usuario hizo clic en una noticia recomendada, esta se considera como un ítem relevante (relevancia igual a 1). Si la noticia fue ignorada (no hubo clic), se considera irrelevante (relevancia igual a 0). Teniendo esto en cuenta, en nuestro proyecto se utilizaron dos tipos de métricas para contrastar los modelos.

■ Precisión (Ranking): AUC, MRR@10 y NDCG@10.

- El **AUC** mide la probabilidad de que nuestro modelo posicione una noticia que recibió clic por encima de una noticia aleatoria que no recibió clic en la misma impresión.
- El **MRR@10** (Mean Reciprocal Rank) evalúa el ranking considerando únicamente la posición de la primera noticia relevante (clickeada) que aparece en el top 10 de las recomendaciones.
- El **NDCG@10** (Normalized Discounted Cumulative Gain) se calcula otorgando mayor importancia a las noticias relevantes que aparecen en las posiciones más altas del top 10. En el caso de MIND, dado que la relevancia es binaria (clic = 1, sin clic = 0), el NDCG penaliza logarítmicamente las recomendaciones correctas que aparecen más abajo en el ranking, reflejando cómo el usuario real escanea rápidamente los primeros resultados.

■ Calidad Informativa: CategoryCoverage@10 y CategoryDiversity@10 (Diversidad), Novelty@10 (Nove-

dad), y ClickbaitScore@10 / HighClickbaitRate@10 (Reducción de contenido clickbait).

4.1. Cálculo de Clickbait Score

El *ClickbaitScore* (*CS*) de una noticia se calcula teniendo en cuenta las siguientes variables basadas en el trabajo de Biyani et al. (2016):

- Presencia de frases comunes de clickbait.
- Presencia de signos de exclamación y/o interrogación.
- Presencia de muchas mayúsculas.
- Poca relación (similitud) entre el título y el abstract.

A modo de ejemplo, para las presencia de frases comunes se tiene una lista de palabras que son consideradas como clickbait. Si una de estas palabras está presente en el título de la noticia o en el abstract de esta se suma cierta cantidad fija al *ClickbaitScore* (*CS*). Así, de manera análoga se analizan el resto de variables para determinar el *CS* de una noticia. Para el caso de similitud se analiza la similitud de los embeddings a través de una similitud coseno entre el título y el abstract, si esta no superan cierto umbral se les suma cierta cantidad al *CS*.

A nivel de ranking, las métricas asociadas a clickbait se definen como:

$$ClickbaitScore@K = \frac{1}{K} \sum_{i=1}^K CS_i \quad (1)$$

$$HighClickbaitRate@K = \frac{1}{K} \sum_{i=1}^K \mathbb{I}(CS_i \geq \tau) \quad (2)$$

Donde τ representa un umbral de tolerancia, que fue elegido empíricamente.

5. Análisis de parámetros

Para el cálculo de la métrica *HighClickbaitRate@K*, el umbral τ fue elegido como el percentil 80 dentro de la distribución global de los scores de clickbait en el dataset.

Para determinar la ponderación óptima de las distintas señales en el modelo de *re-ranking completo*, se realizó una búsqueda en grilla (*grid search*) evaluando combinaciones de pesos para la penalización por clickbait ($\lambda \in \{0,05,0,10\}$), la bonificación por novedad ($\gamma \in \{0,02,0,05\}$) y la penalización por redundancia de categoría ($\delta \in \{0,05,0,10\}$).

Se normalizaron todas las métricas resultantes entre 0 y 1. Luego, se diseñó un *score balanceado* que pondera la

relevancia en un 30 % NDCG@10, 15 % MRR@10, la diversidad en un 20 %, la novedad en un 15 % y el control de clickbait en un 20 % (10 % al *ClickbaitScore* y 10 % al *HighClickbaitRate*). La configuración óptima fue aquella que maximizó este balance, demostrando que pesos moderados ($\lambda = 0,10, \gamma = 0,05$) logran una caída muy leve en relevancia pero una disminución significativa de noticias engañosas.

Table 2. Resumen de las 3 mejores configuraciones evaluadas mediante el Score Balanceado.

λ (CB)	γ (Nov)	δ (Div)	NDCG@10	H.Clickbait@10	Score Bal.
0.10	0.05	0.10	0.356884	0.151536	0.510554
0.10	0.02	0.05	0.359603	0.149296	0.655218
0.10	0.05	0.05	0.358824	0.147016	0.702509




Figure 2. Impacto de distintas combinaciones de pesos de re-ranking en la precisión (NDCG@10) y la exposición a clickbait (HighClickbaitRate@10).

En los experimentos ilustrados en la Figura 2, notamos que existen configuraciones con un menor *HighClickbaitRate@10* que mantienen un *NDCG@10* muy cercano al mejor resultado obtenido. Esto demuestra que la reducción de clickbait no implica necesariamente una pérdida fuerte de relevancia. Sin embargo, el gráfico también evidencia que no todas las configuraciones son igualmente convenientes; algunas reducen el clickbait a costa de un peor desempeño de ranking. La selección final de los hiperparámetros se hizo buscando un punto de equilibrio razonable entre relevancia, exposición a clickbait, novedad y diversidad.

6. Resultados obtenidos

A modo de referencia, la Tabla 3 muestra el rendimiento de modelos complejos sobre MIND reportados en la literatura.

Como se observa en la Tabla 3, arquitecturas neuronales profundas y especializadas alcanzan métricas de precisión bastante altas, destacando especialmente DSSM (AUC de

Table 3. Baselines de referencia del paper MIND (Wu et al., 2020)

Modelo	AUC	MRR	nDCG@10
LibFM	0.5993	0.2823	0.3574
DSSM	0.6431	0.3047	0.3861
Wide&Deep	0.6216	0.2931	0.3712
DeepFM	0.6030	0.2819	0.3571

0.6431 y nDCG@10 de 0.3861) y Wide&Deep. Estos modelos de aprendizaje profundo están diseñados expresamente para maximizar la probabilidad de clic capturando interacciones complejas y no lineales entre los usuarios y los artículos. No obstante, al optimizar puramente por *engagement*, estos modelos operan en gran medida como "cajas negras" y no consideran de forma nativa métricas de calidad informativa (como la reducción de clickbait o la diversidad temática), lo cual es precisamente el problema central que abordamos en nuestro enfoque.

A partir de este contexto, procedimos a evaluar nuestros propios modelos, cuyo principal objetivo es incorporar el control de clickbait sin perder interpretabilidad. Los resultados de los modelos implementados (basados en TF-IDF y nuestro esquema de re-ranking) se detallan en las Tablas 4 y 5.

Table 4. Resultados (Parte 1): Métricas de precisión.

Modelo	AUC	MRR@10	nDCG@10
Random	0.4987	0.2275	0.2869
Most Popular	0.4975	0.2259	0.2879
TF-IDF base	0.5809	0.3091	0.3625
TF-IDF + low cb	0.5868	0.3095	0.3627
TF-IDF + cb + nov	0.5859	0.3096	0.3623
Re-ranking optim.	0.5794	0.3071	0.3588

Table 5. Resultados (Parte 2): Métricas de calidad.

Modelo	CB Score ↓	High CB ↓	Nov@10 ↑
Random	0.1804	0.1850	0.7285
Most Popular	0.1880	0.2489	0.5054
TF-IDF base	0.1823	0.1716	0.7182
TF-IDF + low cb	0.1732	0.1463	0.7218
TF-IDF + cb + nov	0.1733	0.1434	0.7380
Re-ranking optim.	0.1745	0.1470	0.7372

El ranking base TF-IDF logra superar a los métodos Random y Most Popular, lo que confirma que el contenido textual de las noticias (título y abstract) aporta información muy relevante para ordenar las recomendaciones.

Al incorporar una penalización por clickbait, el desempeño general de precisión no disminuye. De hecho, la variante *TF-IDF + low clickbait* obtiene el mejor AUC y el mejor nDCG@10 (Tabla 4), al mismo tiempo que reduce el *ClickbaitScore@10* respecto al TF-IDF base. Esto sugie-

re fuertemente que parte de las noticias con mayor señal de clickbait no eran necesariamente las más útiles para el usuario real o para el ranking de relevancia.

Al agregar además la componente de novedad (*TF-IDF + low clickbait + novelty*), el modelo mantiene un rendimiento muy similar al TF-IDF base pero logra obtener la menor proporción de noticias con alto clickbait (*HighClickbaitRate@10* de 0.1434). Todo esto indica que es sumamente posible introducir criterios informativos adicionales sin afectar de manera relevante la calidad tradicional del ranking (basada puramente en clicks históricos).

7. Conclusiones

En este trabajo se desarrolló un sistema de recomendación de noticias *clickbait-aware* basado en TF-IDF y un esquema de re-ranking interpretable sobre el dataset MIND Small. Los resultados obtenidos muestran empíricamente que es posible reducir señales de clickbait e incorporar métricas de novedad y diversidad, manteniendo un rendimiento en precisión muy similar al del ranking base.

Aunque el desempeño predictivo medido por AUC (0.5868 máximo) aún es menor que el de modelos neuronales más complejos del estado del arte como DeepFM (60.30) o DSSM, el enfoque propuesto tiene la gran ventaja de permitir controlar explícitamente y de manera transparente las métricas de calidad informativa de las recomendaciones. Esto ofrece una alternativa simple, altamente interpretable y ajustable, ideal para plataformas que busquen priorizar la experiencia y confianza del usuario a largo plazo.

Declaración de Uso de IA

Declaramos que durante el desarrollo de este proyecto se utilizaron herramientas de Inteligencia Artificial como asistencias. Específicamente, se empleó IA para apoyar en la depuración y generación de código, así como para asistir en la redacción, estructuración y corrección ortotipográfica del presente documento, asegurando siempre que las ideas, análisis y conclusiones provengan de nuestro propio trabajo y discusión como grupo de estudiantes.

A. Anexo: Patrones léxicos de Clickbait

Para la construcción de nuestro *ClickbaitScore*, utilizamos el cuaderno de ingeniería de características (`FeatureEngineering.MIND.ipynb`) donde implementamos la detección de clickbait basada en heurísticas y expresiones regulares. La lista completa de palabras y frases "gancho" detectadas en los títulos de las noticias es la siguiente:

- *you won't believe / won't believe / can't believe*

- *shocking / will shock you*
- *what happens next / happens next / what happened*
- *this is why / here's why / here is why / the reason why / why you should*
- *what you need to know / everything you need to know / what we know / what to know*
- *things you didn't know*
- *will blow your mind / mind-blowing*
- *secret / secrets / revealed*
- *never seen / must see / you need to see*
- *goes viral*
- *find out*
- *this is what*
- *don't miss*
- *exclusive*
- *unbelievable*
- *jaw-dropping*
- *[Número] things / ways / reasons / tips / facts / tricks*
(Ej. "5 tips", "10 reasons")

Wu, F., Qiao, Y., Chen, J.-H., Wu, C., Qi, T., Lian, J., Liu, D., Xie, X., Gao, J., Wu, W., et al. Mind: A large-scale dataset for news recommendation. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pp. 3597–3606, 2020.

Adicionalmente a estas frases, la función asigna penalizaciones si el título presenta exceso de signos de exclamación (!), uso excesivo de signos interrogativos (dos o más), un alto uso de mayúsculas (ratio superior al 40 %), y finalmente, la penalización continua dada por la diferencia (1 - similitud coseno) entre el contenido del título y su resumen (*abstract mismatch*).

B. Anexo: Link repositorio github

El link del repositorio donde se puede encontrar el código utilizado para el desarrollo de este proyecto se puede encontrar en: <https://github.com/alvrestu/Poyecto-grupo-12-IIC3633-2026-1/upload/main>

Referencias

- Biyani, P., Tsioutsoulouklis, K., and Blackmer, J. "8 amazing secrets for getting more clicks": Detecting clickbaits in news streams using article informality. In *Proceedings of the Thirtieth AAAI Conference on Artificial Intelligence*, pp. 94–100, 2016.
- Natanya, T. and Liebeskind, C. Towards better hebrew clickbait detection: Insights from bert and data augmentation. *PLoS One*, 20(11):e0332342, 2025.
- Scott, K. "you won't believe what's in this paper!" clickbait, relevance and the curiosity gap. *Journal of Pragmatics*, 175:53–66, 2021.